

# Fortgeschrittene Sortiervverfahren

- ❑ Sortieren ist ein sehr intensiv untersuchtes Problem
- ❑ Es gibt eine große Zahl von Algorithmen mit jeweils verschiedenen Varianten
- ❑ Generell ordnet man Sortierverfahren in zwei Gruppen:
  - 1) Vergleichende Sortierverfahren
    - A. Einfache Sortierverfahren
    - B. Fortgeschrittene Sortierverfahren
  - 2) Nicht vergleichende Sortierverfahren

## □ Einfache vergleichende Sortierverfahren

- Sortieren durch Einfügen (insertion sort)
- Sortieren durch Auswählen (selection sort)
- Sortieren durch Vertauschen (bubble sort)

## □ Fortgeschrittene vergleichende Sortierverfahren

- Sortieren durch Mischen (merge sort)
- Sortieren mittels Heapify (heap sort)
- Sortieren durch Gruppieren (quick sort)

## □ Nicht vergleichende Sortierverfahren

- Sortieren durch Zählen (count sort)
- Sortieren durch Fachverteilen (radix sort)

## ❑ Sortieren durch Gruppieren (quick sort)


- Berühmt, schnell, breit einsetzbar
- Nutzt das Prinzip „Teile und Herrsche“

## ❑ Arbeitsweise

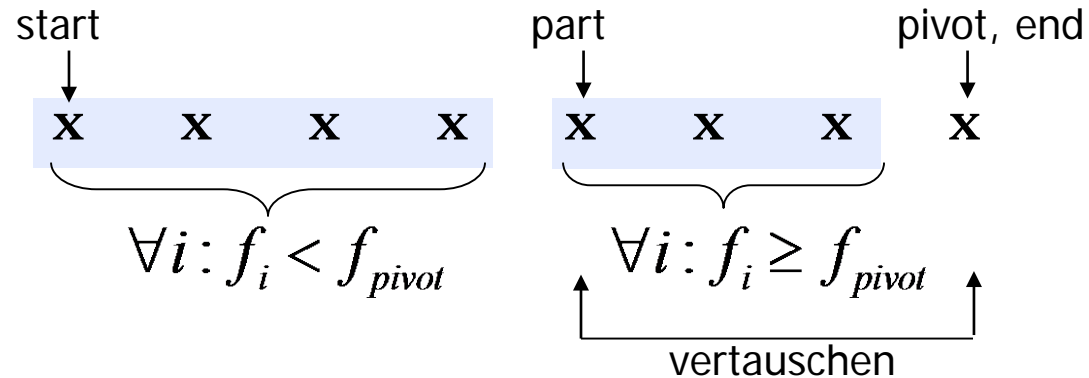
- Die Folge wird in zwei Teilfolgen gruppiert (partition), so dass jedes Element der ersten Folge kleiner ist als jedes Element der zweiten.
- Auf diese Teilfolgen wird das Prinzip dann rekursiv angewendet.
- Die Rekursion endet, wenn man bei einelementigen Teilfolgen angelangt ist.
- Als Trennelement (pivot) für das Gruppieren kann ein beliebiges Folgeelement verwendet werden, z.B. das Letzte, das Erste, oder das Mittlere.

# Quicksort: Prinzip


Anfangssituation



Nach Gruppieren:



Nach Vertauschen:



# Komplexität von Quicksort

□ Wenn es gelingt, die Teilfolgen durch das Gruppieren jeweils zu halbieren, erhalten wir eine Komplexität von:  $T_{bc} = O(n \log n)$

□ Wird jeweils nur eine Teilfolge konstanter Länge abgespalten, so wird  $n$  mal gruppiert und daher:  $T_{wc} = O(n^2)$

□ Im Durchschnitt ist allerdings die Länge der Intervalle abhängig von  $n$  und man braucht nur zweimal mehr Operationen als im besten Fall:

$$T_{ac} = O(n \log n)$$

# Quicksort-Varianten

- ❑ Vorgeschlagene Varianten betreffen die Wahl des Trennwerts für das Gruppieren, der in der vorliegenden Form für das schlechte Verhalten bei nahezu sortierten Folgen verantwortlich ist:
- ❑ Trennindex zufällig aus  $[start, end]$
- ❑ Trennwert als Median aus drei Elementen  $\left\{ f_{start}, f_{\lfloor \frac{end-start}{2} \rfloor}, f_{end} \right\}$
- ❑ Beide Varianten haben sich gut bewährt und sorgen auch bei fast sortierten Folgen für  $O(n \log n)$ .
- ❑ Es ist außerdem vorteilhaft, die kleinere Teilfolge zuerst zu sortieren (Rekursionstiefe minimieren).


# Quicksort mit Listen: Gruppieren

- ❑ Zerlegen einer Folge in zwei Teilfolgen, wovon die eine die kleineren ( $<$ ) Elemente, die andere die größeren ( $\geq$ ) Elemente enthält
  - Als Trennwert pivot wird oft der Wert des ersten Elements genommen.
  - Statt des Vertauschens (swap) werden die Elemente in zwei neue Listen (links und rechts) versetzt (move).
  - Diese werden dann rekursiv sortiert und zu der Resultatliste zusammengesetzt.
  - Die Komplexität des nachfolgenden Gruppierungsverfahren ist, wie bei den Arrays,  $O(n)$ , da die Liste genau einmal abgelaufen wird und jeweils konstanter Aufwand entsteht.



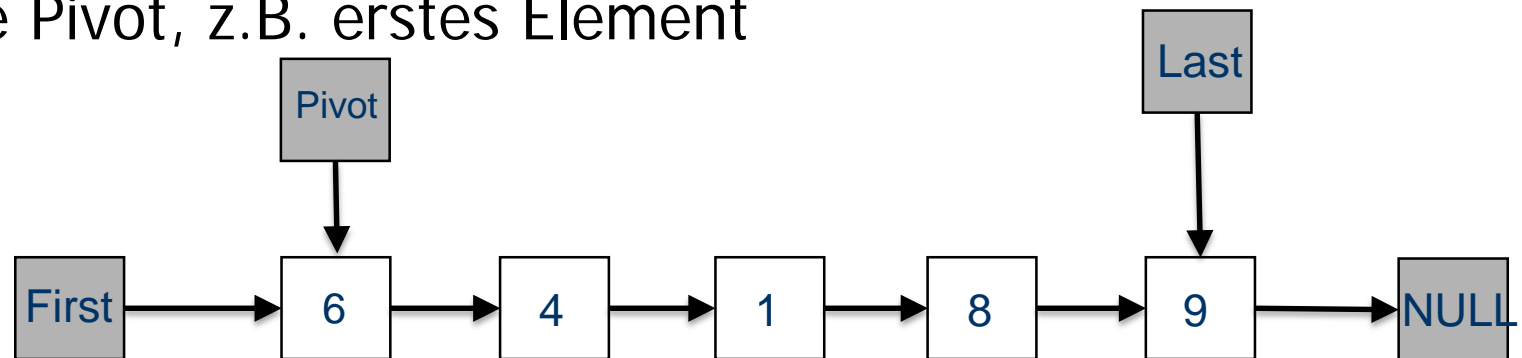
# Sortieren durch Gruppieren (Quicksort)

□ Vor Gruppieren:



□ Partition

➤ 1. Wähle Pivot, z.B. erstes Element




# Sortieren durch Gruppieren (Quicksort)

## □ Partition


### ➤ 2. Liste aufteilen (mit Einfügen am Anfang)

- Neue Liste links mit Elementen  $< \text{Pivot}$



- Neue Liste rechts mit Elementen  $\geq \text{Pivot}$

- Pivotelement




Hinweis: Sind in der Liste noch weitere Elemente mit demselben "Wert" wie das Pivotelement vorhanden, werden diese in die rechte Liste eingefügt. Das Pivotelement selbst ist immer Rückgabewert der Partition.


# Sortieren durch Gruppieren (Quicksort)

## □ Quicksort:


- Rekursives Sortieren der linken und rechten Liste
  - Sortierte linke Liste mit Elementen  $< \text{Pivot}$



- Sortierte rechte Liste mit Elementen  $\geq \text{Pivot}$



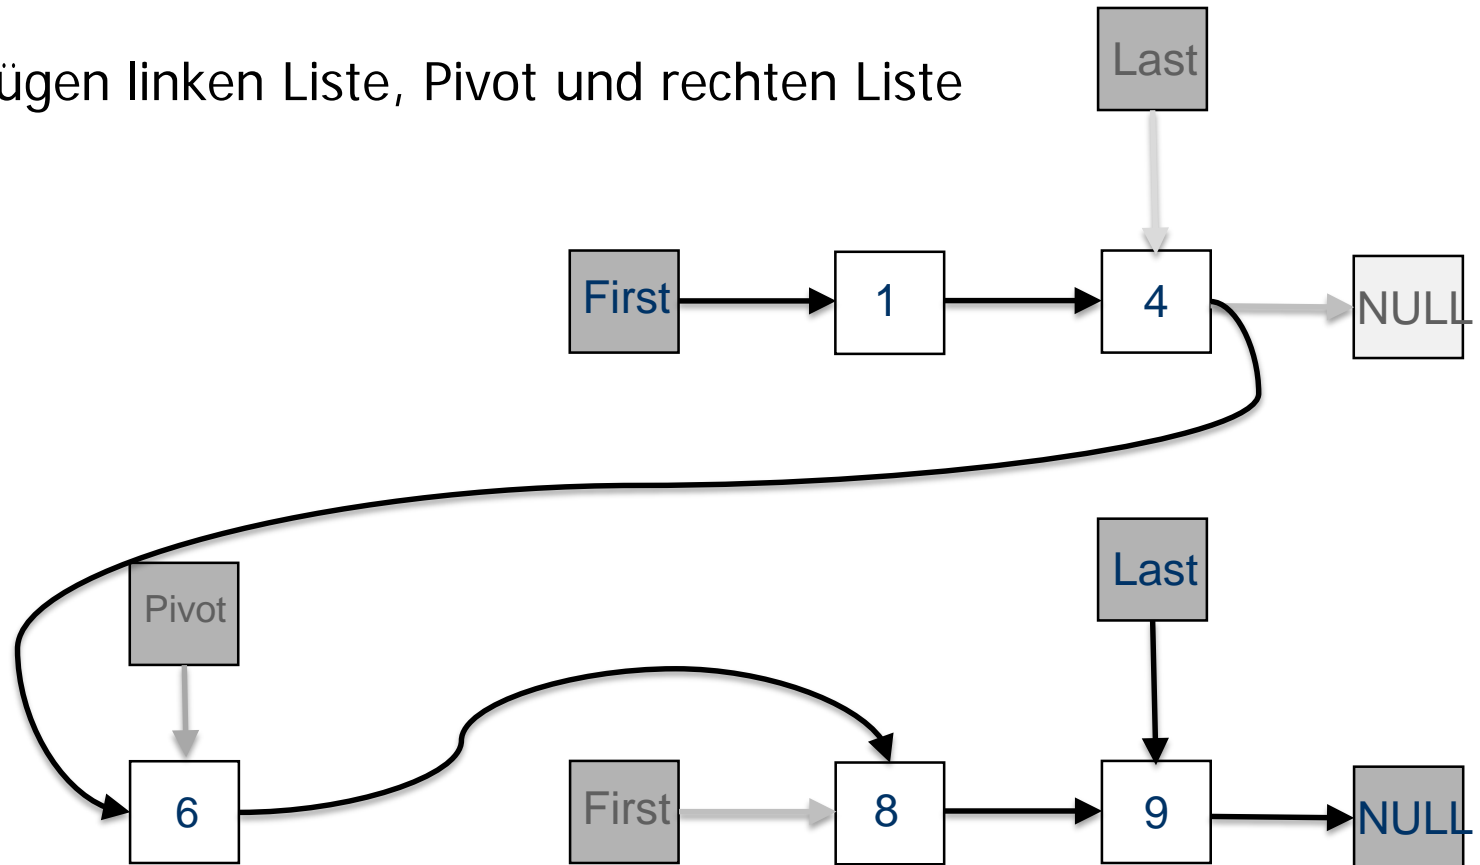
- Pivotelement



# Sortieren durch Gruppieren (Quicksort)

## □ Quicksort:


- Zusammenfügen linken Liste, Pivot und rechten Liste



# Sortieren durch Gruppieren (Quicksort)

## □ Quicksort:


- Resultat: sortierte Liste



# Sortieren durch Gruppieren (Quicksort)

## □ Quicksort:

- Resultat: Sortierte Liste




# Sortieren durch Gruppieren (Variante: Stabiler Quicksort)

## □ Partition mit erstem Element als Pivot Element


### ➤ Liste aufteilen (mit Einfügen am Ende)

- Neue Liste links mit Elementen  $< \text{Pivot}$



- Neue Liste rechts mit Elementen  $\geq \text{Pivot}$

- Pivotelement



Hinweis: Sind in der Liste noch weitere Elemente mit demselben "Wert" wie das Pivotelement vorhanden, werden diese in die rechte Liste eingefügt. Das Pivotelement selbst ist immer Rückgabewert der Partition.

# Quicksort – Pseudocode

## QuickSort ( list tosort )

```
1.  // Abbruchbedingung
2.  if ( tosort.first == tosort.last )
3.      return
4.  else
5.      list left,right

6.      pivot <- Partition(tosort, left, right)
7.      // Rekursion
8.      QuickSort (left)
9.      QuickSort (right)

10.     // Listen Zusammenfügen
11.     if ( left.first == NULL )
12.         tosort.first <- pivot
13.     else
14.         tosort.first <- left.first
15.         left.last.next <- pivot
16.     if ( right.first == NULL )
17.         pivot.next <- NULL
18.         tosort.last <- pivot
19.     else
20.         pivot.next <- right.first
21.         tosort.last <- right.last
```



# Quicksort: Zusammenfassung

## ❑ Sortieren durch Gruppieren (quick sort)

- Berühmt, schnell, breit einsetzbar
- Nutzt das Prinzip „Teile und Herrsche“

## ❑ Arbeitsweise

- Die Folge wird in zwei Teilfolgen gruppiert (partition), so dass jedes Element der ersten Folge kleiner ist als jedes Element der zweiten.
- Auf diese Teilfolgen wird das Prinzip dann rekursiv angewendet.
- Die Rekursion endet, wenn man bei einelementigen Teilfolgen angelangt ist.
- Kann sowohl auf Arrays als auch auf Listen eingesetzt werden
- Als Trennelement (pivot) für das Gruppieren kann
  - Bei Arrays ein beliebiges Folgeelement verwendet werden, z.B. das Letzte, das Erste, oder das Mittlere.
  - Bei Listen am einfachsten das Erste oder das Letzte.

- ❑ Standard Sortierverfahren (Bubble-sort, Insertion-sort, Selection-sort, Quicksort, Merge-sort) sind nicht nur auf Arrays sondern auch auf verkettete Listen anwendbar.
  - Die Komplexität ist dieselbe.
- ❑ Lediglich die auf Indexrechnung beruhenden schnellen Verfahren (count sort) können nicht verwendet werden.

# Anmerkungen: Quicksort vs. Merge-Sort

- ❑ Beide Verfahren, Quicksort und Merge-Sort, benötigen zusätzlichen Speicher
- ❑ Merge-Sort, weil das Mischen in linearer Zeit nur mit einem zweiten Array möglich ist.
- ❑ Quicksort, weil die rekursiven Aufrufe den Programmstapel (program stack) erheblich anwachsen lassen.
  - (Dies kann man mildern, wenn man das Verfahren so umorganisiert, dass kürzere Teilfolgen immer zuerst bearbeitet werden.)
- ❑ Ein Sortierverfahren mit dem gleichen asymptotischen Aufwand und ohne zusätzlichen Speicherbedarf ist Heapsort.

# KOMPLEXITÄT VON VERGLEICHENDEN SORTIERVERFAHREN

# Komplexität von vergleichenden Sortierverfahren

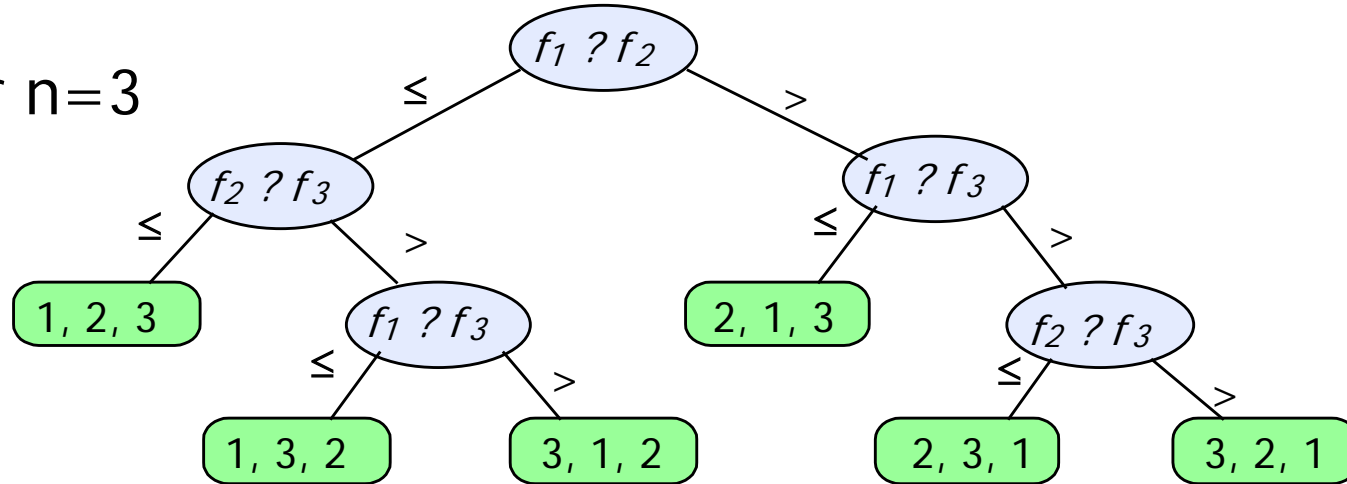
- ❑ Alle bisher besprochenen Sortialgorithmen gehören zur Klasse der Vergleichssortierverfahren
  - Elementaroperation ist der paarweise Größenvergleich
- ❑ Damit ergibt sich Folgendes:
- ❑ Satz: Jedes Sortierverfahren, das auf dem paarweisen Vergleich von Elementen beruht, hat eine Komplexität von:  $\Omega(n \log n)$

# Komplexität von vergleichenden Sortierverfahren

- ❑ Alle bisher besprochenen Sortialgorithmen gehören zur Klasse der Vergleichssortierverfahren
  - Elementaroperation ist der paarweise Größenvergleich
- ❑ Der Ablauf kann in einem binären Entscheidungsbaum wie folgt dargestellt werden:
  - Jeder interne Knoten entspricht dem Vergleich zweier Elemente.
  - Die jeweiligen Teilbäume enthalten die noch erforderlichen restlichen Vergleiche, so dass eine Sortierung gelingt.
  - Jedes Blatt repräsentiert eine der  $n!$  möglichen Permutationen.
  - Der Ablauf einer konkreten Sortierung entspricht einem Pfad von der Wurzel bis zu einem Blatt.

# Entscheidungsbaum

## ■ Beispiel für $n=3$



■ Der längste Pfad von der Wurzel bis zu einem Blatt (= Höhe des Baumes) kennzeichnet die größtmögliche Anzahl von Vergleichen und damit die Laufzeit des Algorithmus.

- Die Worst-case-Komplexität aller solcher vergleichsbasierter Sortierverfahren entspricht daher der Höhe des Baumes.
- Eine untere Schranke für die Höhe des Entscheidungsbaums ist daher auch eine untere Schranke für jedes vergleichsbasierte Sortierverfahren.

# Höhe des Entscheidungsbaums

- ❑ Wie groß ist die Höhe eines Entscheidungsbaumes für  $n$  Elemente mindestens?
- ❑ Es gibt  $n!$  Permutationen, also mindestens  $n!$  Blätter.
- ❑ Ein Binärbaum der Höhe  $h$  hat höchstens  $2^h$  Blätter, daher gilt  $n! \leq 2^h$
- ❑ Durch Logarithmieren  $h \geq \log(n!)$
- ❑ Nach der Stirlingschen Formel gilt  $n! > \left(\frac{n}{e}\right)^n$
- ❑ Also  $h \geq \log\left(\left(\frac{n}{e}\right)^n\right) = n \log n - n \log e = O(n \log n)$



# Vergleichende Sortiervverfahren

- Satz: Jedes Sortiervverfahren, das auf dem paarweisen Vergleich von Elementen beruht, hat eine Komplexität von:  $\Omega(n \log n)$

## □ Einfache Sortierverfahren

- Sortieren durch Auswählen (selection sort)
- Sortieren durch Vertauschen (bubble sort)
- Sortieren durch Einfügen (insertion sort)

## □ Fortgeschrittene Sortierverfahren

- Sortieren durch Gruppieren (quick sort)
- Sortieren durch Mischen (merge sort)

## □ Nicht vergleichende Sortierverfahren

- Sortieren durch Zählen (count sort)
- Sortieren durch Fachverteilen (radix sort)

# NICHT VERGLEICHENDE SORTIERVERFAHREN

# Schnelle, digitale Sortiervverfahren

- ❑ Die bisher diskutierten Sortiervverfahren beruhen auf dem paarweisen Vergleich der Werte der einzelnen Elemente.
- ❑ Eine Verbesserung der asymptotischen Komplexität dieser Verfahren ist nicht möglich.  
(Siehe untere Schranke von  $\Omega(n \log n)$ )

# Schnelle, digitale Sortiervverfahren

- ❑ Unter gewissen Einschränkungen des Wertebereichs können die Werte dazu verwendet werden, den endgültigen Platz direkt anzusteuern.
  - Sortieren durch Zählen (count sort)
  - Sortieren durch Fachverteilen (radix sort)
- ❑ Diese Verfahren sind jedoch nicht immer sinnvoll einsetzbar, z.B. wenn
  - Das Sortieren stabil sein soll
  - Der Wertebereich zu groß ist

# Wiederholung: Sortieren durch Zählen (count sort)

## □ Annahme:

- Die Werte stammen aus einem kleinen Wertebereich, d.h. sie liegen so dicht, dass sie zum Indizieren eines Arrays verwendet werden können.
- Es ist wahrscheinlich, dass Werte mehrfach auftreten.

## □ Idee

- Die Häufigkeit jedes Elements wird ermittelt und daraus wird die endgültige Lage im Zielarray berechnet (streuendes Umspeichern).
- Zum Schluss kann die Folge in das ursprüngliche Array zurückkopiert werden.

# Beispiel: Count-sort

$j:$  1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16

$A_{in}:$ 

3	1	3	3	5	7	2	8	9	7	6	3	8	1	8	8
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

$j:$  1 2 3 4 5 6 7 8 9 10

$C:$  2 1 4 0 1 1 2 4 1 0

1 3 4 8 8 9 10 12 16 17

Werte

Zähler

Position

$A_{out}:$ 

1	1	2	3	3	3	3	5	6	7	7	8	8	8	8	9
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

$k:$  1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16

# Komplexität: Count-sort

## □ Anzahl der Schritte

- Linear in der Zahl der Elemente  $n$
- Linear in der Zahl der Werte  $N$

## □ Also $O(n)$ , wenn $N = O(n)$

## □ Problem

- In vielen praktischen Fällen ist der Wertebereich viel größer als die Zahl der Elemente



# Sortieren durch Fachverteilen (radix sort)

## □ Idee:

- Wir wenden count sort nacheinander auf die Stellen der Werte an
- Begonnen wird bei der kleinsten signifikanten Stelle
- Da count sort stabil ist, bleibt die Ordnung bezüglich der weniger signifikanten Stellen erhalten

## □ Voraussetzungen:

- Werte können in einem Alphabet dargestellt werden
- Die Buchstaben des Alphabets sind total geordnet
- Typische Alphabete: Binär, Dezimal, Hexadezimal

# Sortieren durch Fachverteilen (radix sort)

- ❑ Beispielfolge (Dezimal): 333, 78, 77, 3, 37, 38
- ❑ Sortieren nach der Einerstelle: 333, 3, 77, 37, 78, 38
  - 2 x 3 (333, 3), 2 x 7 (77, 37), 2 x 8 (78, 38)
- ❑ Sortieren nach der Zehnerstelle: 3, 333, 37, 38, 77, 78
  - 1 x 0 (3), 3 x 3 (333, 37, 38), 2 x 7 (77, 78)
- ❑ Sortieren nach den Hunderterstelle: 3, 37, 38, 77, 78, 333
  - 5 x 0 (3, 37, 38, 77, 78), 1 x 3 (333)
- ❑ Notwendige Größe für das Zählerfeld ist immer 10

# Sortieren durch Fachverteilen (radix sort)

## □ Komplexität

### ➤ Annahmen:

- Der Größte Wert ist  $N$
- Die Größe des Wertebereichs für eine Stelle ist  $b$

### ➤ Laufzeit:

- Dann ist die Anzahl der Stellen proportional zu  $\log_b N$
- Für jede Stelle wird count sort verwendet: d.h. der Aufwand pro Stelle ist  $O(n)$
- Also insgesamt  $O(n \log N)$ , mit typischerweise  $\log N \ll n$